


CLASIFICARE BAYESIANA

FORMULAREA PROBLEMEI

- Data o baza de date $D = \{e_1, e_2, \dots, e_n\}$ si o multime de clase $C = \{c_1, c_2, \dots, c_m\}$, a clasifica insemna a gasi o functie $f: D \rightarrow C$ astfel incat fiecarui exemplu din baza de date sa ii corespunda o clasa: $f(e_i) = c_j$.



CLASIFICAREA BAYESIANA

- Se presupune ca toate attributele sunt independente unele de altele si la fel de importante pentru realizarea clasificarii.
- Se bazeaza pe **regula lui Bayes**:

• Date o multime de evenimente observabile : $X = x_1, x_2, \dots, x_n$

si o multime de ipoteze

$$H = h_1, h_2, \dots, h_m$$

presupunand ca o singura ipoteza poate sa apara in acelasi timp atunci probab ca o ipoteza h sa fie adevarata dat fiind un eveniment observabil x este:

$$P(h/x) = \frac{P(x/h)P(h)}{P(x)}$$

Clasa = C_i

*exemplu
(înregistrare în colecția de date)*

unde

$P(x)$ = probab de aparitie a evenimentului x ,

$P(x/h)$ = probab ca data ipoteza h , evenimentul x sa apara.

$P(h/x)$ se numeste probab aposteriori,

$P(h)$ se numeste probab apriori.

APLICATIE

- ◉ **Problema:** Estimam daca valoarea venitului unei persoane este $>50K$ sau $\leq 50K$. (am selectat primele 10 inreg din colectia
- ◉ UCI Machine Learning Repository: Adult Data Set

- ◉ Baza de date:
atribute:
'workclass',
'relationship',
'income'

	workclass	relationship	income
0	State-gov	Not-in-family	$\leq 50K$
1	Self-emp-not-inc	Husband	$\leq 50K$
2	Private	Not-in-family	$\leq 50K$
3	Private	Husband	$\leq 50K$
4	Private	Wife	$\leq 50K$
5	Private	Wife	$\leq 50K$
6	Private	Not-in-family	$\leq 50K$
7	Self-emp-not-inc	Husband	$> 50K$
8	Private	Not-in-family	$> 50K$
9	Private	Husband	$> 50K$

MULTIMEA DE TRAINING

	workclass	relationship	income
0	State-gov	Not-in-family	<=50K
1	Self-emp-not-inc	Husband	<=50K
2	Private	Not-in-family	<=50K
3	Private	Husband	<=50K
4	Private	Wife	<=50K
5	Private	Wife	<=50K
6	Private	Not-in-family	<=50K
7	Self-emp-not-inc	Husband	>50K
8	Private	Not-in-family	>50K
9	Private	Husband	>50K

ATTRIBUTE

- Pentru rezolvare, vezi whiteboard-ul incarcat pe Teams la sectiunea Files -> whiteboards -> 10.05.2025

DISCUTIE

- O problema care poate sa apara atunci cand se foloseste clasificarea bayesiana este aceea ca daca multimea de training nu contine exemple cu destul de multe valori posibile pentru atributul tinta atunci probabilitatea ca acele valori sa apara este zero.
- Acest lucru implica **existenta valorii 0 in matricea probabilitatilor conditionate.**

- ⦿ Acest lucru inseamna ca din start eliminam posibilitatea mai multe posibile valori.
- ⦿ Uneori aceste zerouri sunt justificate dar multimea de training nu ar trebui sa impuna astfel de reguli.
- ⦿ Pentru a elimina aceasta problema (existenta lui 0 in matricea probabilitatilor conditionate) se foloseste **estimatorul Laplace**.

ESTIMATORUL LAPLACE

- Pentru fiecare atribut, fiecare coloana a matricii probabilitatilor conditionate care contine valoarea 0 se modifica astfel:
 - se adauga 1 la numarator si
 - se adauga k la numitor unde k =numarul de valori posibile ale atributului.
- Obs. Acest estimator nu este obligatoriu sa fie 1 ci poate fi orice $\lambda > 0$ si atunci se adauga λ la numarator si se adauga $k\lambda$ la numitor. De obicei se foloseste $\lambda=1$.

EXEMPLU

○ coloana se modifica din:

3/6		4/9
3/6	in	4/9
0/6		1/9

○ coloana se modifica din:

0/6		1/10
2/6	in	3/10
2/6		3/10
2/6		3/10

EVALUAREA MODELULUI DE CLASIFICARE

- Cat de bine estimeaza un clasificator atributul tinta?
- Acuratetea
unui clasificator=
$$\frac{nr.exemple\ clasificat\ corect}{nr.total\ exemple}$$
- rata erorii=
$$\frac{nr.exemple\ clasificat\ incorect}{nr.total\ exemple}$$
- Acuratetea = 1-rata erorii

- ◉ Multimea de training este independenta de multimea de testare.
- ◉ De obicei, alegerea multimii de training se face prin alegerea unui esantion din multimea datelor cunoscute
- ◉ Acuratetea si rata erorii se determina pe multimea de testare.

MATRICEA DE CONFUZIE (VEZI CONFUSION MATRIX-TANAGRA)

- Daca atributul tinta poate lua valorile

$\{c_1, c_2, \dots, c_m\}$, matricea de confuzie este o matrice $m \times m$ cu:

$C[i][j]$ =nr exemple care au sunt clasificate ca avand valoarea c_i iar clasificatorul le-a estimat ca avand fiind in clasa c_j .

Suma pe diagonala principala = nr de exemple clasificate corect

Classifier performances

Error rate			0,0714			
Values prediction			Confusion matrix			
Value	Recall	1-Precision		N	Y	Sum
N	0,8000	0,0000	N	4	1	5
Y	1,0000	0,1000	Y	0	9	9
			Sum	4	10	14