

REGRESIA



TEHNICI DE DATA MINING si MACHINE LEARNING

INVATARE
SUPERVIZATA

Supervised learning

- CLASIFICAREA – ATRIBUT TINTA DISCRET
- REGRESIE – ATRIBUT TINTA CONTINUU

INVATARE
NESUPERVIZATA

Unsupervised learning

- ASOCIERE
- CLUSTERIZARE

REGRESIA

Estimarea valorilor atributului tinta in functie de valorile celorlalte attribute

Atributul tinta: variabila dependenta


Celelalte attribute: variabilele independente


EXEMPLU 1

- Analiza relatiei dintre pretul unui apartament si suprafata lui intr-o zona dintr-un oras.
- Estimarea pretului in functie de suprafata
- Atribut tinta: pret
- Atribut de intrare: suprafata

SUPRAFATA (m2)	PRET (Euro)
90	110000
45	60000
75	80000
60	????

SUPRAFATA (m2)	PRET (Euro)
90	110000
45	60000
75	80000





EXEMPLU 2

- Analiza relatiei dintre greutatea unei persoane si inaltimea sa
- Estimarea greutatii in functie de inaltime sau invers
- Atribut tinta: greutate
- Atribut de intrare: inaltime

Inaltime (cm)	Greutate (kg)
160	54
165	60
170	85
185	90

EXEMPLU 3

- Estimarea punctajului la un test al unui student in functie de nr de ore de studiu pentru test
- Atribut tinta: punctaj
- Atribut de intrare: nr ore studiu

Nr ore studiu	Punctaj test
4	54
8	60
5	85
7	90
16	100
6	???

Tipuri de regresie

Regresie simpla

Estimarea atributului tinta in functie de un singur atribut independent se numeste **regresie simpla**.

- $Y = f(X)$

Regresie multipla

- Daca estimarea se face in functie de mai multe attribute independente atunci avem **regresie multipla**.

- $Y = f(X_1, X_2, \dots, X_k)$

EXEMPLU 4

CYLINDER	DISPLACEMENT	HORSEPOWER	WEIGHT	ACCELERATION	MPG
8	307	130	3504	12	18
8	350	165	3693	11.5	15
8	318	150	3436	11	18
8	304	150	3433	12	16
8	302	140	3449	10.5	17


- Estimarea consumului de combustibil al unei masini in functie de cateva caracteristici ale sale:
- greutate
- marimea motorului
- puterea motorului
- nr. cilindri
- acceleratie
- displacement

REGRESIE SIMPLA

- Se da o multime de puncte in plan. Sa se gaseasca o functie al carui grafic sa se potriveasca cu aceste puncte, sa fie cat mai aproape de aceste puncte.

In imagine aceasta functie este un polinom de grad I, $a+bx$ al carui graphic este o dreapta.

$$y = a + bx$$




Acest tip de regresie se numeste regresie liniara.

wikipedia


Regresia liniara

- Multimea de puncte este aproximata printr-o dreapta.
- Functia care va estima relatia dintre variabila de intrare si variabila de iesire (numit atributul tinta, in acest caz) este liniara
- $Y = a + bX$



y = val exactă
 $\hat{y}$ = val aproximativă
pt i : $|y_i - \hat{y}_i| \rightarrow (y_i - \hat{y}_i)^2$

- Date punctele
- $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$
- vrem sa determinam a si b astfel incat dreapta
- $Y = a + b x$
 - sa aproximeze bine aceste puncte adica
 - sa treaca sufficient de aproape de puncte



Metoda celor mai mici patrate


- Masuram distantele de la fiecare punct la punctul corespunzator de pe dreapta,

- $(x_i, y_i) \rightarrow (x_i, \hat{y}_i)$

distanța = $|y_i - \hat{y}_i|$ pt fiecare $i=1, n$

S = suma patratelor acestor distante

Cautam a si b astfel incat S sa fie minima.



Regresia liniară

Metoda celor mai mici patrate : *minimizăm*

$$\hat{y}_i = a + bx_i$$

$$\sum_{i=1}^n (y_i - \hat{y}_i)^2$$


- $S = \sum_{i=1}^n (y_i - \hat{y}_i)^2 =$
- $S = \sum_{i=1}^n (y_i - a - b x_i)^2$
- $S = S(a, b)$ = funcție de două variabile.
- S este minimă când $\frac{\partial S}{\partial a} = \frac{\partial S}{\partial b} = 0$

• Se rezolvă sistemul


$$a * n + b \sum x_i = \sum y_i$$

$$a * \sum x_i + b \sum x_i^2 = \sum x_i y_i$$

$S(a, b)$ este convexă



$f(x)$ convexă
ex: $f(x) = x^2$
 $f''(x) > 0$




$g(x) = -x^2$
 $g''(x) < 0$

Exemplu – Regresie liniara


Evolutia nr cazurilor confirmate de COV-ID 19 in statul New York

Perioada: 17.03.2020 - 30.03.2020

Data	Nr cazuri confirmate						
3/17/2020	1374						
3/18/2020	2481						
3/19/2020	4597						
3/20/2020	7245						
3/21/2020	10356						
3/22/2020	15168						
3/23/2020	20875						
3/24/2020	25665						
3/25/2020	30811						
3/26/2020	37258						
3/27/2020	44635						
3/28/2020	52318						
3/29/2020	59513						
3/30/2020	68369						



Regresie patratrica



$$y = ax^2 + bx + c$$

Regresia multipla

$$y = a + b_1 X_1 + b_2 X_2 + \dots + b_n X_n.$$

- $X_1, \cancel{X_2}, \dots, X_n$ attribute
- Regresia liniara
- $Y = a + b_1 * x_1 + b_2 * x_2 + \dots + b_n * x_n$
- a = intercept (pt 1 attribute a = intersectia dreptei cu axa Oy)
- $b_1, b_2, \dots, b_n$ = coeficienti = derivatele partiale (panta dreptei de regresie in R pt $n=1$)

