

Metoda gradientului


Gradient descent

Metoda gradientului


- Este o metoda de optimizare iterativa pentru determinarea punctelor de extrem local ale unei functii
- In ML se foloseste pentru determinarea minimului local al functiei cost (loss)
- In regresia liniara minimizeaza
- $S = \sum_{i=1}^n (y_i - \hat{y}_i)^2$

Restriții de aplicare


- Funcția trebuie să fie diferentiabilă de două ori și convexă
- **Diferentiabilă f'' există și este continuă**
- **Convexă $f''(x) > 0$**



nu e diferentiabilă



Gradient



- Pentru o functie definita pe $\mathbb{R}$
 - Gradient = Panta dreptei tangente la un punct de pe graficul functiei
 - $f'(x_0)$ vectorul gradient
-
- Pentru o functie definita pe $\mathbb{R}^2$
 - Gradient = Planul tangent la un punct de pe curba ce reprezinta functia

$$\frac{\partial f}{\partial x} = 2x, \quad \frac{\partial f}{\partial y} = 2y$$

- Ne intereseaza panta de-a lungul fiecarei axe-> derivatele partiale
- Gradientul functiei f intr-un punct p n-dimensional este :

$$\begin{aligned} \nabla f(x,y) &= x^2 + y^2 \\ \nabla f(p=(x_0, y_0)) &= \begin{bmatrix} \frac{\partial f}{\partial x}(x_0, y_0) \\ \frac{\partial f}{\partial y}(x_0, y_0) \end{bmatrix} \\ &= \begin{bmatrix} 2x_0 \\ 2y_0 \end{bmatrix} = 2 \begin{bmatrix} x_0 \\ y_0 \end{bmatrix} \end{aligned} \quad \nabla f(p) = \begin{bmatrix} \frac{\partial f}{\partial x_1}(p) \\ \vdots \\ \frac{\partial f}{\partial x_n}(p) \end{bmatrix}$$

$$x^{(1)} = x^{(0)} - \alpha \underbrace{f'(x^{(0)})}$$

$$[\] = [\] - \alpha \cdot [\]$$

$$\mathbf{x}^{k+1} = \mathbf{x}^k - \alpha_k \mathbf{f}'(\mathbf{x}^k), \quad k = \underline{0}, 1, 2, \dots$$

- $\mathbf{f}'(\mathbf{x}^k) = \nabla f(x_1, \dots, x_n) = (\partial f / \partial x_1, \partial f / \partial x_2, \dots, \partial f / \partial x_n)$
- este gradientul funcției obiectiv în punctul $\mathbf{x}^k$,
- α_k este lungimea pasului efectuat în direcția antigradientului – $\mathbf{f}'(\mathbf{x}^k)$ (learning rate)

Algoritmul

Se alege o valoare initiale $x^{(0)}$, $k=0$

Calculeaza gradient $f'(x^{(k)}) = \nabla f(x_1, \dots, x_n)$

repete

$$x^{k+1} = x^k - \alpha_k f'(x^k)$$

$$K = k+1$$

Pana cand $k > \text{MAX}$ or $||x^{k+1} - x^k|| < \epsilon$

MAX = nr maxim de iteratii

Observatii:

- α_k este un parametru f important (learning rate) rata de invatare
- Rata de învățare mai mică, sunt necesare mai multe iteratii sau poate atinge iterația maximă înainte de a ajunge la punctul optim
- Dacă rata de învățare este prea mare, algoritmul poate să nu convergă la punctul optim (salt în jur) sau chiar să se abată complet.
-

- https://miro.medium.com/v2/resize:fit:1400/1*v5bc1TzeMKpzTAgorjOoHQ.gif
- https://miro.medium.com/v2/resize:fit:1400/format:webp/1*GR914FuA4pVTTXEpVDJ2Ng.png
- https://miro.medium.com/v2/resize:fit:640/1*Z3wjHCFAehYXYG9lOiqiEw.gif
- <https://towardsdatascience.com/gradient-descent-algorithm-a-deep-dive-cf04e8115f21>