

Entropie

DM & ML -
17.05.2025

Indicele Gini

Indicele Gini

• Dacă T este o mulțime de date ce conține înreg din n clase (dec) atributul tinta are n valori discrete posibile, indicele Gini se definește:

$$gini(T) = 1 - \sum_{j=1}^n p_j^2$$

$$p_j = \frac{nr \text{ aparitii ale clasei } j}{nr \text{ dinreg ale colectiei } T}$$

• Dacă T se împarte în submulțimi astfel încât T are N elemente, T₁ are N₁ elemente, ..., T_k are N_k elemente, atunci indicele Gini al diviziunii

$$gini_{diviziune}(T) = \sum_{i=1}^k \frac{N_i}{N} gini(T_i) + \sum_{i=1}^k \frac{N_i}{N} gini(T_i)$$

	workclass	relationship	income
0	State-gov	Not-in-family	<=50
1	Self-emp-not-inc	Husband	<=50
2	Private	Not-in-family	<=50
3	Private	Husband	<=50
4	Private	Wife	<=50
5	Private	Wife	<=50
6	Private	Not-in-family	<=50
7	Self-emp-not-inc	Husband	>50
8	Private	Not-in-family	>50
9	Private	Husband	>50

$$entropie(T) = -p_1 \log_2 p_1 - p_2 \log_2 p_2 \dots - p_n \log_2 p_n$$

$$entropie(T) = -p_Y \log_2 p_Y - p_N \log_2 p_N$$

$$= -\frac{4}{10} \log_2 \frac{4}{10} - \frac{6}{10} \log_2 \frac{6}{10}$$


=

$$octave: > -(4/10) * \log_2(4/10) - (6/10) * \log_2(6/10)$$

ans = 0.9710

$$gini(T) = 1 - p_Y^2 - p_N^2 = 1 - (4/10)^2 - (6/10)^2 =$$

$$= 1 - 16/100 - 36/100 = 1 - 52/100 = 48/100 = 0.48$$



• Cel mai bun atribut = cel pentru care indicele $gini_{diviziune}(T)$ este cel mai mic.

$$gini(T) = 1 - p_Y^2 - p_N^2 = 1 - (5/10)^2 - (5/10)^2 = 1 - (1/2)^2 - (1/2)^2 =$$

$$= 1 - 1/4 - 1/4 = 1 - 1/2 = 1/2 = 0.5$$

• Indicele Gini ne da probabilitatea ca doua elemente alese la intamplare din colectia data sa nu fie in aceeași clasa.

$$gini(T) = 1 - p_Y^2 - p_N^2 = 1 - (1)^2 - (0)^2 =$$

$$= 1 - 1 = 0$$

$$entropie(T) = -1 \log_2 1 - 0$$

= 0


Cel mai bun atribut

• Cel mai bun atribut = cel pentru care $INFO_{diviziune}(T)$ este cel mai mare (entropie diviziune cea mai mica).

Sa se determine cel mai bun atribut pentru diviziune folosind criteriul Gini

income este atributul tinta cu valorile >50 K, <=50K

1. Calculam indicele Gini diviziune dupa workclass



workclass	<=50K	>50K	
state_gov	1	0	T1
self_emp	1	1	T2
private	5	2	T3

$$gini(T1) = 0$$

$$gini(T2) = 0.5$$

$$gini(T3) = 1 - (5/7)^2 - (2/7)^2 = 1 - (25+4)/49 = 1 - 29/49 = 20/49$$


$$dini_diviz_workclass = (1/10) * gini(T1) + (2/10) * gini(T2) + (7/10) * gini(T3) =$$

$$= (1/10) * 0 + (2/10) * 0.5 + (7/10) * (20/49) = 0.3857$$

$$= \frac{2}{10} \cdot \frac{1}{2} + \frac{7}{10} \cdot \frac{20}{49} = \frac{1}{10} + \frac{2}{7} = \frac{27}{70} = 0.3857$$

Tema:

1. Sa se continue exercitiul cu aflarea celui mai bun atribut
2. Sa se identifice cel mai bun atribut din arbore de decizie urmator si valoarea corespunzatoare pe ramuri.



Diviz nodului 2

workclass	<=50K	>50K	
state_gov	0	0	T1
self_emp	1	1	T2
private	1	1	T3

Diviz nodului 3:

workclass	<=50K	>50K	
state_gov	1	0	T1
self_emp	0	0	T2
private	2	1	T3