

Pregătirea datelor

Etape in pregatirea datelor

Curatarea datelor (Data Cleaning)

Selectarea atributelor (Feature Selection):

Transformarea datelor

Crearea de noi attribute (Feature Engineering)

Reducerea dimensionalitatii
(Dimensionality Reduction)

Curatarea datelor (Data Cleaning)

- Identificarea datelor lipsa si tratarea acestora

Metode:

- inlocuirea datelor lipsa
 - - cu o valoare scalara - functia `**fillna(**`
 - - cu valoarea urmatoarea sau anterioara: fill - forward - functia `**ffill(**` sau backward - functia `**bfill(**`
 - - cu Mean, Median sau Mode - functia `**fillna(**`
 - * Mean = medie - pentru tipul numeric
 - * Median = mediana - pentru tipul numeric
 - * Mode = valoarea care apare cel mai frecvent - pentru tipul object
- stergerea liniilor sau coloanelor care contin date lipsa - functia `dropna()`
- Identificarea si corectarea erorilor in datele existente
 - - erori datorate formatului
 - - stergerea valorilor aberante (outliers)
 - - netezirea datelor zgomotoase (smooth noisy data)
 - - rezolvarea neconcordanțelor.

Selectarea atributelor (Feature Selection)

- Identificarea atributelor de intrare relevante problemei ce trebuie rezolvate

Transformarea datelor

- Normalizarea datelor
- Modificarea tipului atributelor
 - discretizarea atributelor
 - convertirea de la tipul string in tipul numeric

Crearea de noi attribute (Feature Engineering)

- Crearea de noi attribute derivate din cele originale

Reducerea dimensionalitatii (Dimensionality Reduction)

Crearea de proiectii ale datelor (maparea datelor)

Curatarea datelor (Data Cleaning)

- Identificarea datelor lipsa si tratarea acestora
- identificarea si corectarea erorilor in datele existente