

Procesarea limbajului natural si analiza de text

Tematică:

Curs 1

ce este NLP, aplicații practice, concepte de bază (tokenizare, entități, modele), diferențe NLP–NLU–NLG, biblioteci Python folosite.

Lab 1

exerciții simple în Python → tokenizare, frecvențe de cuvinte, extragere de cuvinte-cheie, pentru a aplica practic teoria.

Curs 2

- introducere în expresii regulate (regex) și rolul lor în NLP;
- aplicații → căutare modele în text, tokenizare, curățare, validare, extragere informații, normalizare;
- exemple → curățare tweet-uri cu re (regex), apoi aceeași sarcină cu NLTK;
- discuții despre stopwords și diferențe între regex și NLTK;
- biblioteca spaCy.

Lab 2

- ✓ exerciții de curățare și preprocesare text (ex. tweet-uri) folosind regex (re), NLTK și spaCy;
- ✓ eliminare hashtag-uri, mențiuni, link-uri, caractere speciale, stopwords;
- ✓ tokenizare și reconstruire text curat;
- ✓ export rezultate în fișiere CSV;
- ✓ aplicarea expresiilor regulate și compararea cu instrumentele NLP standard.

Curs 3

- tehnici NLP pentru diverse sarcini (grupare cuvinte, analiză semantică, rezumare, recunoaștere entități, analiză sentiment, clasificare text);
- exemple cu TF-IDF și K-Means pentru gruparea conversațiilor chatbot;
- utilizarea NLTK pentru clustering și frecvența cuvintelor;
- biblioteci suplimentare → Gensim (Word2Vec, rezumare), spaCy (vectori semantici), fastText, scikit-learn (Affinity Propagation);
- discuții despre modele lingvistice (n-gram, HMM, embeddings, RNN, Transformer);
- lematizare vs. stemare (diferențe, avantaje, aplicații).

Lab 3

- exerciții de grupare conversații cu TF-IDF și K-Means (scikit-learn, NLTK);
- exportarea matricei TF-IDF și a rezultatelor clustering-ului în fișiere;
- preprocesare → tokenizare, eliminare stopwords, curățare text;
- analiza frecvenței cuvintelor;
- exerciții cu lematizare și stemare în Python;

- implementări practice de rezumare text (gensim, sumy).

Curs 4

- metode pentru măsurarea similitudinii semantice între propoziții în NLP;
- măsuri bazate pe șiruri (Levenshtein, Jaccard, fuzz.ratio etc.);
- măsuri bazate pe modele lingvistice (cosinus, BERT, Transformers, rețele siameze);
- aplicații → recuperare informații, clasificare text, rezumare, analiză social media;
- Word Mover's Distance (WMD) cu Word2Vec;
- Analiza Semantică Latentă (LSA) pentru relații semantice;
- vizualizare prin nor de cuvinte (Word Cloud) cu frecvența termenilor.

Lab 4

- exerciții de comparare a propozițiilor cu măsuri diferite (cosinus, fuzz.ratio, Jaccard, Levenshtein, WMD);
- implementarea LSA pentru analiză semantică;
- utilizarea încorporărilor Word2Vec pentru calcule de distanță;
- generarea și exportul rezultatelor în fișiere CSV;
- construirea unui nor de cuvinte pe baza frecvenței/lematizării termenilor.

Curs 5

- analiza sentimentelor (definiție, rol și aplicații → social media, feedback clienți, reputație brand);
- tipuri: polaritate (pozitiv, negativ, neutru), analiză gradată, detecție emoții, analiză pe aspecte, analiză multilingvă;
- abordări → bazate pe reguli/lexicon (TextBlob, VADER, SentiWordNet), bazate pe ML/transformers (BERT, GPT);
- pași de preprocesare → curățare, tokenizare, POS tagging, eliminare stopwords, stemming/lemmatizare;
- metode și librării → NLTK, TextBlob, VADER, SentiWordNet, Hugging Face Transformers;
- interpretarea scorurilor de polaritate și subiectivitate, vizualizarea distribuției sentimentelor;
- antrenarea modelelor ML pentru clasificare pe date etichetate.

Lab 5

- exerciții practice de analiză a sentimentelor pe fișiere CSV;
- implementări cu TextBlob, NLTK (SentimentIntensityAnalyzer), VADER, SentiWordNet, Hugging Face Transformers;

- calcul polaritate, subiectivitate, scor compus;
- clasificare în recenzii pozitive/negative/neutre;
- reprezentări grafice ale distribuției sentimentelor;
- compararea metodelor lexicon-based și ML-based;
- aplicarea analizei pe date reale (abstracte, recenzii, texte sociale).

Curs 6


- creare chatbot simplu în Python cu **spaCy** și **NLTK**;
- utilizarea modelului de limbă română *ro_core_news_sm* pentru tokenizare, POS tagging și entități;
- interfață grafică cu **tkinter** (fereastră chat, câmp input, buton trimitere); identificarea unor cuvinte-cheie (NLP, ENTITATE) și furnizarea de răspunsuri predefinite;
- dacă nu există regulă, se oferă răspuns implicit;
- observație → chatbot-ul este bazat pe reguli, nu înțelege contextul real; pentru avansat → se pot folosi modele NLP mai complexe (transformers).

Lab 6

- implementarea unui chatbot cu Python, spaCy și tkinter;
- preluarea mesajului utilizatorului, procesare cu model spaCy în română;
- reguli simple pentru cuvinte-cheie și generarea răspunsurilor corespunzătoare;
- afișarea conversației în fereastra de chat;
- exerciții practice → adăugarea de noi reguli, extinderea vocabularului chatbot-ului.

Curs - 1

NLP - "Natural Language Processing" este o ramură a inteligenței artificiale (IA) care se ocupă de interacțiunea **între computere și limbajul natural al oamenilor**.



Natural Language Processing (NLP) este o ramură a învățării automate (ML) care drept scop sa reușeasca implementarea computerele să înțeleagă limbajul uman. Este folosit pentru a crea modele lingvistice, aplicații de traducere lingvistică precum Google translate, asistenți virtuali etc,

Scopul principal al NLP este de a permite calculatoarelor să înțeleagă, să interpreteze și să genereze limbaj uman.

NLP implică utilizarea unor tehnologii precum **procesarea limbajului natural**, **învățarea automată** (machine learning), **analiza semantică**, recunoașterea de entități și alte tehnici pentru a realiza aceste funcționalități complexe de prelucrare a limbajului uman.

Exemple de aplicații NLP:

1. Traducere lingvistică
2. Rezultatele motorului de căutare
3. Asistenți inteligenți
4. Automatizarea serviciului pentru clienți
5. Filtre de e-mail
6. Analiza sondajelor
7. Roboți de chat
8. Monitorizare Social Media
9. Analiza textului
10. Text predictive
11. Detectarea știrilor false și a hărțuirii cibernetice

<https://aclanthology.org/2020.nlp4if-1.1.pdf/>

<https://aclanthology.org/2020.trac-1.23.pdf>

1. Traducere lingvistică

Traducătorii online sunt acum instrumente puternice datorită procesării limbajului natural.

Acest lucru se datorează în mare parte NLP amestecat cu capacitatea de "învățare profundă". Învățarea profundă este un subdomeniu al învățării automate, care ajută la descifrarea intenției, cuvintelor și propozițiilor utilizatorului.

2. Rezultatele motorului de căutare

Motoarele de căutare nu mai folosesc doar cuvinte cheie pentru a ajuta utilizatorii să ajungă la rezultatele căutării. Ei analizează acum **intenția oamenilor** atunci când caută informații prin NLP. Motoarele de căutare pot, **să îmbunătățească** rezultatele pe care le arată.

Completarea automată a căutării este un alt exemplu de NLP într-un motor de căutare. Această funcție **prezice** ceea ce ați putea căuta, astfel încât să puteți pur și simplu să faceți clic pe ea și să vă scutiți de dificultatea de a o introduce text. **Căutarea inteligentă** este un alt instrument care este condus de NLP și poate fi integrat în funcțiile de căutare a **comerțului electronic**. Acest instrument învață despre intențiile clienților cu fiecare interacțiune, apoi oferă rezultate conexe.

3. Asistenți inteligenți

Asistenții inteligenți, care au fost odată din în domeniul "science fiction", sunt acum cunoscuți. De exemplu asistenți inteligenți **Siri sau Alexa** (Amazon's Alexa or Apple's Siri), folosesc recunoașterea vocală pentru a înțelege întrebările noastre, apoi folosesc generarea limbajului natural (un subdomeniu al NLP) pentru a răspunde la aceste întrebări. Ei sunt instruiți în mod eficient de către proprietarul lor și, ca și alte aplicații ale NLP, învață din experiență pentru a oferi asistență mai bună și mai adaptată.

4. Automatizarea serviciului pentru clienți

Serviciul pentru clienți costă foarte mult companiile atât în timp, cât și în bani. Găsirea unor modalități de a contracara acest lucru prin automatizare este esențială.

Chatbots ar putea fi primul lucru la care vă gândiți, dar există de fapt o serie de alte moduri în care NLP poate fi utilizat pentru a automatiza serviciul pentru clienți.

NLP poate fi folosit pentru a detecta **sentimentul și cuvintele cheie în e-mailuri**. Aceste e-mailuri pot primi apoi răspunsuri automate sau pot fi atribuite automat echipei relevante. Aceasta înseamnă că e-mailurile clienților nu se pierd în "cloud", iar problemele sunt rezolvate prompt.

În mod similar, rutarea biletelor de asistență sau asigurarea faptului că interogarea corectă ajunge la echipa potrivită poate fi, de asemenea, automatizată. Acest lucru

se face prin utilizarea NLP pentru a înțelege ce are nevoie clientul pe baza limbajului pe care îl folosește. Acest lucru este apoi combinat cu tehnologia de învățare profundă pentru a executa rutarea.

5. Filtre de e-mail

Un filtru de spam este probabil cea mai cunoscută și consacrată aplicație a filtrelor de e-mail. Spam-ul reprezintă aproximativ **85% din traficul global total de e-mail la nivel mondial**, astfel încât aceste filtre sunt esențiale.

Dar filtrele au evoluat, de asemenea, ca o modalitate de a ajuta oamenii să-și păstreze căsuța de e-mail organizată. De exemplu, în gmail e-mailurile dvs. pot fi sortate după diverse criterii: principale, sociale, promoții etc.

În spatele tuturor acestor filtre, NLP „este la lucru”. Pe măsură ce e-mailurile intră în căsuța de e-mail, acestea sunt scanate automat folosind **instrumente de clasificare a textului** și de **extragere a cuvintelor cheie**, susținute de tehnologia NLP.

Biblioteci Python utilizate pentru clasificarea textului- care oferă implementări eficiente ale algoritmilor de învățare automată pentru sarcini precum analiza sentimentului, clasificarea tematică și alte tipuri de clasificări textuale.

scikit-learn: învățarea automată și include diverse **algoritmi de clasificare text**.

NLTK (Natural Language Toolkit): oferă diverse funcționalități pentru **procesarea limbajului natural, inclusiv clasificare text**. Aceasta include implementări ale unor algoritmi clasici precum Naive Bayes.

spaCy: oferă suport pentru clasificarea textului, inclusiv folosind algoritmi de mașină suportată de spațiu vectorial (SVM).

TensorFlow și Keras: biblioteci puternice pentru învățarea automată

PyTorch: pentru a construi și antrena modele de clasificare text.

Transformers (Hugging Face): furnizează acces la o serie de modele pre-antrenate de ultimă generație, inclusiv BERT, GPT etc altele, care pot fi folosite pentru clasificarea textului.

Există mai multe pachete Python utile **pentru extragerea de cuvinte cheie din texte**. Aceste pachete utilizează diverse metode pentru a identifica cuvintele cheie, cum ar fi **frecvența cuvintelor, analiza sintactică, analiza semantică etc**.

NLTK (Natural Language Toolkit): oferă funcționalități de extragere a cuvintelor cheie, inclusiv utilizarea frecvențelor cuvintelor pentru a identifica cele mai importante cuvinte.

Python

```
from nltk import FreqDist, word_tokenize
text = "Există mai multe pachete Python utile pentru extragerea de cuvinte cheie din texte"
tokens = word_tokenize(text)
freq_dist = FreqDist(tokens)
keywords = freq_dist.most_common(5) # primele 5 cuvinte cheie
```

TextBlob: este o bibliotecă simplă pentru procesarea limbajului natural și include funcționalități pentru analiza sentimentului și extragerea de cuvinte cheie.

Python

```
from textblob import TextBlob

text = "This is a sample text for keyword extraction."
blob = TextBlob(text)
keywords = blob.noun_phrases
```

scikit-learn: oferă un modul `TfidfVectorizer` care poate fi folosit pentru a calcula termeni importanți în funcție de frecvența lor în documente.

python

```
from sklearn.feature_extraction.text import TfidfVectorizer
corpus = ["This is a sample text for keyword extraction."]
vectorizer = TfidfVectorizer()
X = vectorizer.fit_transform(corpus)
feature_names = vectorizer.get_feature_names_out()
keywords = [feature_names[i] for i in X.sum(axis=0).argsort()[0, -5:]]
# primele 5 cuvinte cheie
```

RAKE (Rapid Automatic Keyword Extraction): implementare Python a algoritmului RAKE care se concentrează pe extragerea rapidă și automată a cuvintelor cheie.

python

```
from rake_nltk import Rake

text = "This is a sample text for keyword extraction."
r = Rake()
r.extract_keywords_from_text(text)
keywords = r.get_ranked_phrases()[:5] # primele 5 cuvinte cheie
```

Gensim: oferă funcționalități pentru modelarea tematică și încorporarea de cuvinte, care pot fi utilizate pentru a extrage cuvinte cheie semantice.

python

```
from gensim.summarization import keywords
text = "This is a sample text for keyword extraction."
keywords = keywords(text, words=5, split=True, scores=True)
```

6. Analiza sondajului

Când trimiteți sondaje, fie clienților, angajaților sau oricărui alt grup, trebuie să puteți extrage informații utile din datele pe care le primiți înapoi.

Cu toate acestea, cantități mari de informații sunt adesea imposibil de analizat manual. Aici este „locul” în care procesarea limbajului natural este utilă - în special **analiza sentimentelor** și instrumentele de analiză a feedback-ului care **scanează textul pentru emoții pozitive, negative sau neutre**.

7. Chatbots

Chatbot-urile sunt o modalitate excelentă de a gestiona eficient interogările serviciului pentru clienți, reducând simultan sarcina echipei umane. Acestea sunt disponibile instantaneu, 24/7, ceea ce înseamnă că, clienții ar putea să nu trebuiască ... **Chatbots** ajută la reducerea costurilor.

Nimic din toate acestea nu ar fi posibil fără NLP, care permite chatbot-urilor să asculte ceea ce le spun clienții și să ofere un răspuns adecvat. Acest răspuns este îmbunătățit și mai mult atunci când sunt utilizate instrumente de analiză a sentimentelor și de clasificare a intenției.

(Microsoft Copilot Studio <https://web.powerva.microsoft.com/tryit>)

8. Monitorizarea rețelelor sociale

Social media (SM) → pentru a comunica, pentru a citi și a asculta, pentru a vorbi și a fi auziți...

O companie poate monitoriza SM pentru a afla mai multe despre modul în care se simte clientul dvs. prin ceea ce comentează, postează sau ascultă.

Soluția? Folosim NLP, mai precis instrumente de analiză a sentimentelor pentru a urmări modul în care se simt clienții. Apoi puteți fi notificat cu privire la orice probleme cu care se confruntă și le puteți rezolva cât mai repede apar.

9. Analiza textului

Companiile din zilele noastre trebuie să proceseze o mulțime de date și text nestructurat. Organizarea și analizarea manuală a acestor date este inefficientă, subiectivă și adesea imposibilă din cauza volumului.

NLP este special prin faptul că are capacitatea de a înțelege aceste „grămezi” de informații nestructurate. **Instrumente precum extractoarele de cuvinte cheie, analiza sentimentelor și clasificatorii de intenție, sunt deosebit de utile.**

Aceste instrumente care sunt alimentate de NLP pot revizui cantități mari de date extrase din sondaje, social media, e-mailuri etc. și vă pot oferi analize detaliate în câteva secunde.

10. Text predictiv

Textul predictiv a devenit atât de înrădăcinat în viața noastră de zi cu zi, încât nu ne gândim adesea la ceea ce se întâmplă în spatele scenei. După cum sugerează și numele, textul predictiv funcționează prin prezicerea a ceea ce urmează să scrieți. În timp, textul predictiv învață de la dvs. și de la limbajul pe care îl utilizați pentru a crea un **dictionar personal**.


Textul **predictiv și vs autocorecție** au evoluat foarte mult și acum avem aplicații precum **Grammarly**, care se bazează pe **procesarea limbajului natural și învățarea automată**. Avem, de asemenea, **Gmail Smart Compose**, care vă termină propozițiile pe măsură ce tastați.

Observatie: Adoptarea procesării limbajului natural este o necesitate.

Concepte de procesare a limbajului natural NLP vs. NLU vs. NLG

Procesarea limbajului natural (NLP), înțelegerea limbajului natural (NLU) și generarea limbajului natural (NLG) sunt toate subiecte conexe și sunt **distincte**.

NLU și NLG sunt doar componente ale NLP. Având în vedere modul în care se intersectează, acestea sunt de obicei confundate în cadrul conversației.



Ce este procesarea limbajului natural?

NLP (Natural Language Processing) este o tehnică de inteligență artificială care permite mașinilor să proceseze și să înțeleagă limbajul așa cum fac oamenii, folosind **lingvistica computațională combinată cu învățarea automată, învățarea profundă și modelarea statistică**.

Prin NLP, computerele **nu înțeleg doar sensul, ci și sentimentul și intenția**. Ei învață apoi la locul de muncă, stocând informații și analizează contextul pentru a-și consolida răspunsurile viitoare.

NLP poate aduce o mulțime de beneficii mediului de afaceri.

Aproape jumătate dintre companiile de astăzi folosesc aplicații bazate pe procesarea limbajului natural (NLP), iar una din patru companii intenționează să înceapă să folosească tehnologia NLP în următoarele 12 luni. **Serviciul pentru clienți este cel mai important exemplu de utilizare NLP. 52%** dintre profesioniștii IT la nivel mondial raportează că compania lor utilizează sau ia în considerare utilizarea soluțiilor NLP pentru a îmbunătăți experiența clienților.

<https://newsroom.ibm.com/IBMs-Global-AI-Adoption-Index-2021?lnk=ushpv18ai3>

NLP nu este perfect, în mare parte datorită ambiguității limbajului uman. Cu toate acestea, a parcurs un drum lung ...

Procesarea limbajului natural, care a evoluat din lingvistica computațională, utilizează metode din diferite discipline, cum ar fi informatica, inteligența artificială, lingvistica și știința datelor, pentru a permite computerelor să înțeleagă limbajul uman atât în formă scrisă, cât și verbală.

Lingvistica computațională se concentrează mai mult pe aspecte ale limbajului. Procesarea limbajului natural subliniază utilizarea învățării automate și a tehnicilor de învățare profundă pentru a finaliza sarcini, cum ar fi traducerea limbajului sau răspunsul la întrebări. Procesarea limbajului natural funcționează prin **preluarea datelor nestructurate și convertirea acestora într-un format de date structurate**. Acest lucru se realizează prin identificarea entităților (un proces numit recunoașterea entităților) și identificarea modelelor de cuvinte, folosind metode precum **tokenizarea, stemming-ul și lemmatizarea**, care examinează formele rădăcinilor cuvintelor. De exemplu, sufixul -ed pe un cuvânt, cum ar fi **called**, indică timpul trecut, dar are același infinitiv de bază (to call) ca și verbul la timpul present **calling**.

Deși există o serie de algoritmi NLP, diferite abordări tind să fie utilizate pentru diferite tipuri de sarcini lingvistice. De exemplu, lanțurile Markov ascunse tind să fie utilizate pentru **etichetarea părților de vorbire**. Rețelele neuronale recurente ajută la generarea secvenței corespunzătoare de text. N-grame, un model de limbaj simplu (LM), atribuie probabilități propozițiilor sau frazelor pentru a prezice acuratețea unui răspuns. Aceste tehnici lucrează împreună pentru a sprijini tehnologii pentru **chatbots** sau produse de recunoaștere a vorbirii, cum ar fi **Alexa sau Siri**.

Ce este înțelegerea limbajului natural?

Înțelegerea limbajului natural este un subset al procesării limbajului natural, care utilizează analiza sintactică și semantică a textului și a vorbirii pentru a determina sensul unei propoziții. Sintaxa se referă la structura gramaticală a unei propoziții, în timp ce semantica face aluzie la sensul intenționat. NLU stabilește, de asemenea, **o ontologie relevantă**: o structură **de date care specifică relațiile dintre cuvinte și fraze**. În timp ce oamenii fac acest lucru în mod natural în conversație, combinația acestor analize este necesară pentru ca o mașină să înțeleagă sensul intenționat al diferitelor texte. Abilitatea noastră de a distinge între omonime și omofone ilustrează bine nuanțele limbajului. Exemplu:

Alice is swimming against the current./ The current version of the report is in the folder.

În prima propoziție, cuvântul, **current** este un substantiv. Verbul care îl precede, înotul (to swim), oferă un context suplimentar cititorului, permițându-ne să concluzionăm că ne referim la curgerea apei în ocean.

A doua propoziție folosește cuvântul **curent**, dar ca **adjectiv**. Substantivul pe care îl descrie, versiunea, denotă mai multe iterații ale unui raport, permițându-ne să identificăm faptul că ne referim la starea cea mai actualizată a unui fișier.

Aceste abordări sunt, de asemenea, utilizate în mod obișnuit în extragerea datelor pentru a înțelege **atitudinile consumatorilor**. În special, analiza sentimentelor permite brandurilor să-și monitorizeze feedback-ul clienților mai îndeaproape, permițându-le să grupeze comentariile pozitive, negative sau neutre - din social media. Prin revizuirea comentariilor cu **sentimente negative**, companiile sunt capabile să identifice și să abordeze mai rapid potențialele zone problematice din produsele sau serviciile lor.

Ce este generarea limbajului natural?

Generarea limbajului natural este un alt subset al procesării limbajului natural. În timp ce înțelegerea limbajului natural se concentrează pe înțelegerea citirii pe computer, generarea limbajului natural permite computerelor să scrie. NLG este procesul de producere a unui răspuns text în limbaj uman bazat pe unele intrări de date. Acest text poate fi, de asemenea, convertit într-un **format de vorbire prin servicii text-to-speech**.

NLG cuprinde, de asemenea, capacități de rezumare a textului care generează rezumate din documente introduse, menținând în același timp integritatea informațiilor.

Inițial, sistemele NLG au folosit șabloane pentru a genera text. Dar, de-a lungul timpului, sistemele de generare a limbajului natural au evoluat prin aplicarea lanțurilor Markov ascunse, a rețelelor neuronale recurente și a transformatoarelor, permițând generarea de text mai dinamică în timp real.

Ca și în cazul NLU, aplicațiile NLG trebuie să ia în considerare regulile lingvistice bazate pe morfologie, lexicoane, sintaxă și semantică pentru a face alegeri cu privire la modul de formulare a răspunsurilor în mod corespunzător. Acestea abordează această problemă în trei etape:

- Planificarea textului: În această etapă, conținutul general este formatat și ordonat într-o manieră logică.
- Planificarea propozițiilor: Această etapă ia în considerare punctuația și fluxul textului, descompunerea conținutului în paragrafe și propoziții și încorporarea pronumelor sau conjuncțiilor acolo unde este cazul.

Această etapă ține cont **de acuratețea gramaticală**, asigurându-se că regulile privind punctația și conjugările sunt respectate. De exemplu, timpul trecut al verbului alerga (*run*) is *ran*.