

Sentiment Analysis

Curs 5-NLP

Analiza sentimentelor (sau extragerea opiniei) este o [tehnică de procesare a limbajului natural \(NLP\)](#) utilizată pentru a determina dacă datele sunt pozitive, negative sau neutre. Analiza sentimentelor este adesea efectuată pe date textuale pentru a ajuta companiile să monitorizeze sentimentul mărcii și al produsului în [feedback-ul clienților](#) și să înțeleagă nevoile clienților.

1. Ce este analiza sentimentelor?
2. Tipuri de analiză a sentimentelor
3. De ce este importantă analiza sentimentelor?
5. Cum funcționează analiza sentimentelor?
6. Provocări ale analizei sentimentului
7. Aplicații de analiză a sentimentelor

Ce este analiza sentimentelor?

Analiza sentimentelor (cunoscută și sub numele de minerit de opinie sau AI emoțională) este un subdomeniu al NLP care măsoară înclinația opiniilor oamenilor (pozitive / negative / neutre) în cadrul textului nestructurat.

Analiza sentimentelor poate fi efectuată folosind două abordări: **bazată pe reguli**, **bazată pe învățarea automată**.

Se folosește pentru: Analiza pieței; monitorizare social media; analiza feedback-ului clienților; analiza sentimentului mărcii sau a reputației; studii de piață

Biblioteci Python pentru analiza de sentiment: NLTK, TextBlob, **VADER**, SpaCy, Gensim, **CoreNLP**-

Tipuri de analiză a sentimentelor

Analiza sentimentelor se concentrează pe polaritatea unui text (*pozitiv, negativ, neutru*), dar și pentru a detecta sentimente și emoții specifice (*furios, fericit, trist* etc.), urgență și chiar [intenții](#) (*interesat vs. neinteresat*).

Analiza sentimentelor gradate

Dacă precizia polarității este importantă în funcție de context, se recomandă să extindeți categoriile de polaritate pentru a include diferite niveluri pozitive și negative:

- Foarte pozitiv
- Pozitiv
- Neutru
- Negativ
- Foarte negativ

Aceasta este de obicei denumită analiză **gradată sau fină a sentimentelor** și ar putea fi utilizată pentru a interpreta evaluările de 5 stele într-o recenzie, de exemplu:

- Foarte pozitiv = 5 stele
- Foarte negativ = 1 stea

<https://www.ibm.com/think/topics/sentiment-analysis>

Cum funcționează analiza sentimentelor




Fig 1. Flux de etape interconectate care transformă date textuale brute în informații utile despre atitudinea sau emoția exprimată.

După fiecare evaluare și ajustare, sistemul devine mai precis, ceea ce îl face potrivit pentru monitorizarea automată a opiniilor, recenziilor sau reacțiilor publice.

1. **Preprocesarea datelor textuale** – Se elimină semnele de punctuație inutile, datele textuale sunt tokenizate în cuvinte sau expresii individuale, textul este normalizat, iar cuvintele de legătură (stop words) sunt eliminate.
2. **Extragerea caracteristicilor** – Textul este analizat pentru identificarea unigramelor, bigramelor sau a altor tipare lingvistice. După aceasta, toate caracteristicile relevante sunt extrase din datele textuale.
3. **Clasificarea sentimentului** – Diferiți algoritmi de învățare automată sunt utilizați pentru clasificarea sentimentelor. Acești algoritmi sunt antrenați pe seturi de date în care sentimentul fiecărui eșantion de text este cunoscut. În această etapă, algoritmi învață tipare și asocieri între caracteristicile extrase și sentiment.
4. **Etichetarea sentimentului** – După ce clasificatorul este antrenat, acesta este folosit pentru a identifica date textuale noi, nevăzute anterior. Clasificatorul încearcă să determine sentimentul din text, atribuind etichete de sentiment pe baza instruirii primite.
5. **Agregarea sentimentului** – Aceasta se realizează pentru a analiza seturi de date mai mari sau pentru a monitoriza tendințele de-a lungul unei perioade de timp.
6. **Evaluation – Evaluarea**
Evaluarea modelelor de analiză a sentimentului – Modelele utilizate pentru analiza sentimentului sunt optimizate pentru a-și îmbunătăți performanța. Acuratețea predicțiilor este măsurată pe un set de date separat și ajustată pentru a crește precizia și a reduce părtinirea (biasul).
7. **Fine-tuning – Ajustare fină (optimizare)**
Modelul este îmbunătățit pe baza rezultatelor evaluării. Se ajustează parametrii, se adaugă date suplimentare de antrenament sau se schimbă tehnici de preprocesare pentru a obține rezultate mai bune.

Detectarea emoțiilor

Analiza sentimentelor de detectare a emoțiilor vă permite să depășiți polaritatea pentru a detecta emoții, cum ar fi fericirea, frustrarea, furia și tristețea.

Multe sisteme de detectare a emoțiilor utilizează lexicoane (adică liste de cuvinte și emoțiile pe care le transmit) sau algoritmi complecși de **învățare automată**.

Unul dintre dezavantajele utilizării lexicoanelor este că oamenii își exprimă emoțiile în moduri diferite.

Analiza sentimentului bazată pe aspect

În cadrul analizei sentimentelor, este important să identificăm **aspectele sau caracteristicile specifice** despre care oamenii vorbesc și **tonul** cu care le menționează ca de exemplu **pozitiv, neutru sau negativ**.

Analiza multilingvă a sentimentelor

Analiza multilingvă a sentimentelor poate fi dificilă. Aceasta implică preprocesare și resurse. Majoritatea acestor resurse sunt disponibile online (de exemplu, lexicoane de sentimente), în timp ce altele trebuie create (de exemplu, corpusuri traduse sau algoritmi de detectare a zgomotului).

Alternativ, puteți detecta automat limba în **texte cu un clasificator de limbi**, apoi puteți instrui un model personalizat de analiză a sentimentelor pentru a clasifica textele în limba aleasă.

De ce este importantă analiza sentimentelor?

Pe măsură ce oamenii își exprimă tot mai des gândurile și emoțiile în mediul online și pe rețelele de socializare, analiza sentimentelor devine un instrument esențial pentru monitorizarea și înțelegerea opiniilor exprimate în diferite tipuri de date. Prin analiza automată a feedback-ului clienților – cum ar fi opiniile din sondaje sau conversațiile din social media – companiile pot identifica ce anume îi face pe clienți fericiți sau frustrați, putând astfel adapta produsele și serviciile pentru a răspunde mai bine nevoilor acestora.

Beneficiile generale ale analizei sentimentelor

1. Sortarea datelor la scară largă

Analiza sentimentelor permite companiilor să proceseze rapid și rentabil cantități uriașe de date nestructurate, oferind o imagine clară asupra percepțiilor clienților.

2. Analiză în timp real

Prin analiza sentimentelor, problemele critice pot fi identificate pe măsură ce apar, oferind organizațiilor posibilitatea de a reacționa imediat și de a preveni situațiile negative.

3. Criterii consecvente de evaluare

Etichetarea textului în funcție de sentiment este, **în mod natural, subiectivă, fiind influențată de experiențele și convingerile personale ale fiecărui evaluator**. Prin implementarea unui sistem centralizat de analiză a sentimentelor, companiile pot aplica **criterii uniforme** tuturor datelor, ceea ce crește acuratețea și fiabilitatea rezultatelor obținute.

Observație:

Aplicațiile analizei sentimentelor sunt extrem de variate și aproape nelimitate, de la evaluarea satisfacției clienților până la monitorizarea reputației unei mărci sau a tendințelor din piață.

Abordarea bazată pe norme (lexicon-based approach)

Abordarea bazată pe norme reprezintă o metodă practică de analiză a textului, care nu necesită procesul de instruire al unui model și nu implică utilizarea algoritmilor de învățare automată. În cadrul acestei metode, analiza se realizează prin aplicarea unui set de reguli predefinite, în funcție de care fragmentele de text sunt clasificate în categorii de sentiment — pozitiv, negativ sau neutru.

Aceste reguli se fundamentează pe lexicoane (**liste de cuvinte asociate cu anumite stări afective sau polarități emoționale**). Din acest motiv, metoda mai este denumită și abordare bazată pe lexic.

Printre cele mai utilizate instrumente care implementează această abordare se numără **TextBlob**, **VADER (Valence Aware Dictionary and sEntiment Reasoner)** și **SentiWordNet**, fiecare oferind mecanisme distincte de evaluare a sentimentului pe baza structurilor lexicale.

SentiWordNet este integrat **ca o resursă lexicală disponibilă în cadrul NLTK**. **SentiWordNet** este o **resursă lexicală orientată emoțional**, derivată din WordNet

Avantaje: nu necesită date de antrenament; poate fi aplicat direct pe texte în limba engleză; ușor de integrat în sisteme lexicon-based.

Dezavantaje: sensibil la **ambiguitatea cuvintelor** (un cuvânt are mai multe sensuri, dar doar unele sunt pozitive); nu ține cont de **contextul frazei**; funcționează bine pentru limba engleză, mai puțin pentru alte limbi.

Exemplu:

```
from nltk.corpus import sentiwordnet as swn
from nltk import download
# resursele necesare
download('sentiwordnet')
download('wordnet')
# cuvânt analizat
word = 'good'

# 'a' = adjective
synsets = list(swn.senti_synsets(word, 'a'))
print(f"Toate sensurile posibile pentru cuvântul '{word}' ca adjectiv:\n")
# Parcurgem fiecare sens și afișăm scorurile asociate
for i, s in enumerate(synsets):
    print(f"{i+1}. Nume synset: {s.synset.name()}")
    print(f"Definiție: {s.synset.definition()}")
```

```
print(f" Scor pozitiv: {s.pos_score():.2f}")
print(f" Scor negativ: {s.neg_score():.2f}")
print(f" Scor obiectiv: {s.obj_score():.2f}")
print("=" * 10)Explicatii:
```

senti_synsets('good', 'a') caută **toate sensurile posibile** ale cuvântului „good” în **SentiWordNet**; 'a' înseamnă **adjectiv (adjective)**.

Alte coduri posibile pentru părțile de vorbire:

- 'n' = substantiv (*noun*)
- 'v' = verb (*verb*)
- 'a' = adjectiv (*adjective*)
- 'r' = adverb (*adverb*)

list(...) transformă rezultatul într-o listă Python.

Atentie: SentiWordNet este construit peste **WordNet**, care atribuie scoruri de sentiment **doar** synset-urilor pentru:

- **Substantive (N)**
- **Verbe (V)**
- **Adjective (A)** — include și „adjective satellite” din WordNet, tratate tot ca adjective
- **Adverbe (R)**

Alte clase (determinatori, prepoziții, conjuncții, interjecții, numerale, pronume etc.) **nu au scoruri de sentiment** în SentiWordNet

Analiza sentimentelor folosind TextBlob:

TextBlob este o bibliotecă Python pentru procesarea datelor textuale. Oferă un API consistent pentru scufundarea în sarcini comune de procesare a limbajului natural (NLP), cum ar fi etichetarea părților de vorbire, extragerea frazelor, analiza sentimentelor etc.

Cele două măsuri care sunt folosite pentru a analiza sentimentul sunt:

- Polaritate – vorbește despre cât de pozitivă sau negativă este opinia
- Subiectivitatea – vorbește despre cât de subiectivă este opinia

TextBlob(text).sentiment ne oferă valorile Polaritate, Subiectivitate. Polaritatea variază de la -1 la 1 (1 este mai pozitiv, 0 este neutru, -1 este mai negativ)

Subiectivitatea variază de la 0 la 1(0 fiind foarte obiectiv și 1 fiind foarte subiectiv)

```
res = TextBlob("I love horror films").sentiment  
res
```

```
Sentiment(polarity=0.5, subjectivity=0.6)
```

Exemplu de sentiment TextBlob

Codul Python:

```
from textblob import TextBlob  
#function to calculate subjectivity  
def getSubjectivity(review):  
    return TextBlob(review).sentiment.subjectivity  
#function to calculate polarity  
def getPolarity(review):  
    return TextBlob(review).sentiment.polarity  
  
#function to analyze the reviews  
def analysis(score):  
    if score < 0:  
        return 'Negative'  
    elif score == 0:  
        return 'Neutral'  
    else:  
        return 'Positive'
```

Numărați recenzii pozitive, negative, neutre.

```
tb_counts = fin_data. Analysis.value_counts()
```

```
tb_counts
```

Analiza sentimentelor folosind VADER

VADER înseamnă Valence Aware Dictionary și Sentiment Reasoner. Sentimentul Vader spune dacă afirmația este pozitivă sau negativă și specifică și intensitatea emoției.

Suma intensităților pos, neg, neu= 1.

compound variază de la -1 la 1 și este metrica utilizată pentru a desena sentimentul general

positive if compound ≥ 0.5
neutral if $-0.5 < \text{compound} < 0.5$
negative if $-0.5 \geq \text{compound}$

Analiza sentimentelor folosind SentiWordNet

SentiWordNet utilizează baza de date WordNet. Este important să obțineți POS-ul, lema fiecărui cuvânt. (<https://www.geeksforgeeks.org/nlp-synsets-for-a-word-in-wordnet/>).

SentiWordNet atribuie scoruri de sentiment (pozitive, negative sau neutre) cuvintelor în funcție de gradul lor de pozitivitate, negativitate sau neutralitate. Aceasta oferă informații semantice care pot fi folosite pentru a evalua sentimentul unui text pe baza cuvintelor individuale. $(-1,1)$

Aspecte importante despre SentiWordNet:

1. **Scorurile de sentiment:** Fiecare cuvânt din SentiWordNet este asociat cu trei scoruri numerice, corespunzătoare gradului de pozitivitate, negativitate și neutralitate. Aceste scoruri variază între 0 și 1, unde 0 indică absența sentimentului, iar 1 indică un sentiment puternic.
2. **Exemplu de utilizare:** Pentru a evalua sentimentul unui text folosind SentiWordNet, se pot calcula scorurile medii ale cuvintelor din text. Cu toate acestea, acest lucru poate fi simplist și nu ia în considerare contextul sau modul în care cuvintele sunt combinate în propoziții.
3. **Limitări:** SentiWordNet are limitări, deoarece nu ia în considerare contextul complex al limbajului uman. De exemplu, unele cuvinte pot avea sensuri diferite în funcție de context, iar SentiWordNet nu abordează această ambiguitate în mod direct.
4. **Disponibilitate:** SentiWordNet este disponibilă ca parte a proiectului WordNet și poate fi accesată prin intermediul unor biblioteci și pachete de limbaj natural, cum ar fi nltk (Natural Language Toolkit) în Python.
5. **Integrare cu algoritmi de analiză de sentiment:** SentiWordNet poate fi integrată cu algoritmi de analiză de sentiment pentru a îmbunătăți evaluarea sentimentului în texte.

SentiWordNet nu este o soluție perfectă și nu acoperă întotdeauna complexitatea interpretării sentimentului în contexte variate.

Sa se calculeze sentimentul si polaritatea folosind metodele

Sa se reprezinte grafic evolutia sentimentului

transformers este o bibliotecă Python dezvoltată de Hugging Face, care permite folosirea modelelor de inteligență artificială bazate pe transformers (precum BERT, GPT, RoBERTa, DistilBERT, XLM-R etc.). Această bibliotecă îți oferă acces la mii de modele pre-antrenate pentru sarcini de tip: analiză de sentiment (sentiment analysis), clasificare de text, traducere automată, summarization, recunoaștere de entități (NER), generare de text (text generation), întrebări și răspunsuri (question answering).

pipeline = interfață rapidă pentru modele Hugging Face.

Modelele pre-antrenate de analiză a sentimentului:

Modelele de analiză a sentimentului de tip transformer, precum BERT (Bidirectional Encoder Representations from Transformers) și GPT (Generative Pre-trained Transformer), sunt modele avansate de învățare automată concepute pentru a înțelege limbajul natural într-un mod similar cu oamenii. Acestea au fost antrenate pe cantități uriașe de text, învățând structura, semantica și contextul cuvintelor din propoziții. Datorită acestui proces de pre-antrenare, pot fi adaptate cu ușurință la diverse sarcini de procesare a limbajului natural, cum ar fi analiza sentimentului, clasificarea textelor sau generarea de conținut.

BERT – Bidirectional Encoder Representations from Transformers:

BERT, dezvoltat de Google, este un model de limbaj natural care analizează textul în ambele direcții (stânga-dreapta și dreapta-stânga), permițându-i să înțeleagă mai bine contextul fiecărui cuvânt dintr-o propoziție. A fost antrenat pe un volum foarte mare de date neetichetate și pe sarcini de înțelegere a limbajului, ceea ce îi conferă capacitatea de a capta relații semantice complexe între cuvinte. Pentru analiza sentimentului, un model BERT poate fi fine-tuned (ajustat) pe un set de date etichetat cu sentimente — de exemplu, recenzii pozitive, negative și neutre — pentru a recunoaște automat tonul emoțional al unui text.

GPT – Generative Pre-trained Transformer:

GPT, creat de OpenAI, este un alt tip de model transformer, însă cu o arhitectură auto-regresivă: **el prezice următorul cuvânt dintr-o secvență, pe baza celor anterioare.** Datorită acestei proprietăți, GPT este folosit în principal pentru generarea de text (**chatboturi**, completare de propoziții etc.), dar poate fi adaptat și pentru sarcini de clasificare precum analiza sentimentului. Totuși, fiind un model generativ, GPT necesită ajustări suplimentare atunci când este folosit ca model discriminativ (pentru clasificare, nu generare).

Antrenarea modelelor proprii de analiză a sentimentului:

Procesul tipic de învățare supervizată implică următorii pași:

1. Colectarea datelor
2. Etichetarea datelor – asociază fiecărui text o etichetă de sentiment (manual sau semi-automat).
3. Preprocesarea textului – curățare, tokenizare, normalizare, eliminare stop words.
4. Extragerea caracteristicilor – Bag of Words sau Word Embeddings.
5. Antrenarea modelului – folosind algoritmi precum SVM, Logistic Regression, Random Forest sau modele BERT/GPT ajustate.
6. Evaluarea performanței – măsurarea preciziei, recall, F1-score etc.
7. Optimizare și implementare – ajustarea parametrilor și integrarea modelului într-o aplicație.

Legătura cu `from transformers import pipeline`:

Instrucțiunea „`from transformers import pipeline`” permite utilizarea directă a modelelor pre-antrenate fără a fi nevoie să antrenezi un model propriu.

Funcția `pipeline` oferă o interfață simplă care:

- încarcă automat un model pre-antrenat (precum BERT),
- pregătește textul pentru analiză,
- rulează inferența,
- returnează rezultatele într-un format ușor de interpretat.

Exemplu practic

```
from transformers import pipeline

analyzer = pipeline("sentiment-analysis")

rezultat = analyzer("Acest produs este excelent!")

print(rezultat)
```

Rezultatul va fi de forma `[{'label': 'POSITIVE', 'score': 0.9997}]`, indicând un sentiment pozitiv cu un scor ridicat.

Modelele precum BERT și GPT reprezintă fundamentele procesării moderne a limbajului natural. Instrucțiunea „`from transformers import pipeline`” este poarta de

intrare către aceste modele — oferind o metodă rapidă, prietenoasă și eficientă pentru analiza sentimentelor sau alte sarcini NLP cu doar câteva linii de cod.

Aplicatie - Interpretarea analizei sentimentului pentru metodele TextBlob, NLTK, VADER și Hugging Face Transformers

Analiza sentimentului reprezintă procesul de determinare a atitudinii emoționale exprimate într-un text, clasificându-l drept **pozitiv**, **negativ** sau **neutru**. Diferitele metode de procesare a limbajului natural (NLP) utilizează algoritmi și modele distincte pentru estimarea polarității sentimentelor.

1. **Metoda TextBlob determină** polaritatea sentimentului pe baza unei valori numerice cuprinse între -1 și 1, unde:

- Valorile **pozitive**, apropiate de **1**, indică un **sentiment pozitiv**;
- Valorile **negative**, apropiate de **-1**, indică un **sentiment negativ**;
- Valoarea **0** semnifică un **sentiment neutru**.

Astfel, clasificarea finală se poate interpreta astfel:

- **Positive**, dacă polaritatea este > 0 ;
- **Negative**, dacă polaritatea este < 0 ;
- **Neutral**, dacă polaritatea este $= 0$.

TextBlob utilizează o abordare bazată pe lexicon și analiză gramaticală, fiind potrivită pentru texte de dimensiuni reduse și limbaj formal.

2. **NLTK – SentimentIntensityAnalyzer**

Modulul **SentimentIntensityAnalyzer** din biblioteca **NLTK** (Natural Language Toolkit) calculează un **scor compus** (compound score), tot într-un interval cuprins între -1 și 1, care reflectă intensitatea și direcția sentimentului:

- Valorile **pozitive** sugerează un **sentiment pozitiv**;
- Valorile **negative** indică un **sentiment negativ**;
- Valoarea **0** reflectă un **sentiment neutru**.

Interpretarea categorială este similară:

- **Positive**, dacă scorul > 0 ;
- **Negative**, dacă scorul < 0 ;
- **Neutral**, dacă scorul $= 0$.

Această metodă combină reguli lingvistice și un lexicon specializat, fiind eficientă pentru texte în limba engleză, în special în mediul online (comentarii, recenzii, mesaje scurte).

3. **VADER – Valence Aware Dictionary and sEntiment Reasoner**

Metoda **VADER**, inclusă tot în cadrul **NLTK**, reprezintă o extensie optimizată a analizei lexicale, destinată textelor informale (social media, recenzii, postări).

Și în acest caz, scorul **compus** al sentimentului variază între -1 (sentiment extrem de negativ) și 1 (sentiment extrem de pozitiv).

Clasificarea sentimentului (coloana `Tip_Sentiment_VADER`) se realizează conform regulilor:

- **Positive**, dacă scorul compus > 0 ;
- **Negative**, dacă scorul compus < 0 ;
- **Neutral**, dacă scorul compus $= 0$.

VADER are avantajul de a recunoaște nuanțe emoționale, utilizând reguli pentru intensificatori (ex. „foarte”, „extrem”) și semne de punctuație (ex. „!!!”) care pot modifica intensitatea sentimentului.

4. Hugging Face Transformers

Abordarea bazată pe **Hugging Face Transformers** utilizează modele de tip **deep learning**, precum **BERT** sau **RoBERTa**, care au fost pre-antrenate pe cantități masive de date textuale. Aceste modele oferă o analiză contextuală mai avansată, depășind limitările lexicale ale metodelor tradiționale.

Rezultatele sunt exprimate prin două componente:

- **Sentiment_HF_Label** – eticheta sentimentului prezis (de regulă, „POSITIVE” sau „NEGATIVE”);
- **Sentiment_HF_Score** – scorul de încredere asociat etichetei, cu valori cuprinse între **0** și **1**.

Interpretarea rezultatelor se poate detalia astfel:

- **Sentiment foarte pozitiv** – label = POSITIVE și score ≥ 0.75 ;
- **Sentiment pozitiv moderat** – label = POSITIVE și $0.5 \leq \text{score} < 0.75$;
- **Sentiment ușor pozitiv** – label = POSITIVE și score < 0.5 ;
- **Sentiment foarte negativ** – label = NEGATIVE și score ≥ 0.75 ;
- **Sentiment negativ moderat** – label = NEGATIVE și $0.5 \leq \text{score} < 0.75$;
- **Sentiment ușor negativ** – label = NEGATIVE și score < 0.5 ;
- **Sentiment neutru** – dacă eticheta nu este nici „POSITIVE”, nici „NEGATIVE”, sau dacă scorul este apropiat de 0.5.

Comparativ cu metodele bazate pe lexicon (TextBlob, VADER, NLTK) modelele Transformers captează mai bine **contextul semantic** și **relațiile dintre cuvinte**, oferind o acuratețe superioară în interpretarea emoțiilor implicite.

<http://ai.stanford.edu/~amaas/data/sentiment/>

http://ai.stanford.edu/~amaas/papers/wvSent_acl2011.pdf

<https://learn.microsoft.com/en-us/azure/ai-services/language-service/sentiment-opinion-mining/language-support?source=recommendations>

<https://learn.microsoft.com/en-us/azure/ai-services/language-service/sentiment-opinion-mining/quickstart?tabs=windows&pivots=programming-language-csharp>

<https://www.geeksforgeeks.org/part-speech-tagging-stop-words-using-nltk-python/>