

Laborator 1

Procesarea Big Data în Databricks.

Navigarea în Big Data începe cu catalog, continuă cu scheme, apoi tabele și, în final, cu conținutul datelor.

Crearea unui set de date (batch processing)

```
data = [  
    (1, "Student 1", "IT", 5000),  
    (2, " Student 2", "HR", 4200),  
    (3, " Student 3", "IT", 6000),  
    (4, " Student 4", "Finance", 5500)  
]  
columns = ["id", "nume", "departament", "salariu"]  
df = spark.createDataFrame(data, columns)  
df.show()
```

Observatie: datele sunt procesate **ca un set** (batch); Spark distribuie automat datele;

DataFrame = structură Big Data.

Databricks a scris fișiere **Parquet** în Data Lake, a creat fișierul/, a înregistrat tabela în **Unity Catalog**

Datele sunt fișiere în Data Lake, nu rânduri într-o bază clasică.

„Data Lake-ul este locul unde sunt stocate fizic datele, sub formă de fișiere.

Spark doar le citește și le procesează, iar Databricks ne oferă o interfață ușoară.”

1. Stocarea datelor (Storage) -

```
df.write.format("delta").saveAsTable(  
    "`utm-master-an2-sd&ia-dl`.mironela.angajati"  
)
```

datele sunt salvate în format **Delta Lake**; avantaj: versionare, consistență, scalabilitate; echivalentul unui **data lake table**.

pipeline-ul Spark s-a finalizat complet, df.write.format("delta").saveAsTable(...) a rulat cu

success, tabelul **a fost creat/suprascris** în `utm-master-an2-sd&ia-dl`.mironela.angajati

Se poate observa integrarea **Spark ↔ SQL ↔ Unity Catalog**.

```
%sql
```

```
SELECT *
```

```
FROM `utm-master-an2-sd&ia-dl`.mironela.angajati;
```

Catalog Explorer > utm-master-an2-sd&ia-dl > mironela >			
angajati			
Overview Sample Data Details Permissions Policies History Lineage Insights Quality			
Filter lineage All assets Up and Downstream Last 3 months See lineage graph			
Name	Direction	Type	Last activity
Laborator 1 Big Data	Downstream	Notebook	9 minutes ago
Laborator 1 Big Data	Upstream	Notebook	14 minutes ago

Lineage-ul ne arată că notebook-ul *Laborator 1 Big Data* este atât sursa, cât și consumatorul tabelului angajati. Astfel putem urmări exact cine a creat datele și unde sunt folosite.

%sql

```
CREATE TABLE `utm-master-an2-sd&ia-dl`.mironela.angajati_it AS  
SELECT *
```

```
FROM `utm-master-an2-sd&ia-dl`.mironela.angajati
```

```
WHERE departament = 'IT';
```

CREATE TABLE definește structura, Spark DataFrame creează și procesează datele.

În ambele cazuri, rezultatul final este același: fișiere în Data Lake guvernate de Unity Catalog.

Spark DataFrame se utilizează când:

- realizăm procesare Big Data;
- transformăm date;
- combinăm surse;
- lucrăm cu batch / streaming.

Folosim CREATE TABLE când:

- definim structuri;
- face tabele finale;
- utilizăm mai mult în SQL;

Spark = procesare

SQL = structură

Data Lake = stocare fizică

Catalog Explorer > utm-master-an2-sd&ia-dl > mironela >

angajati

☆

Open in a dashboard

Share

Create

Overview

Sample Data

Details

Permissions

Policies

History

Lineage

Insights

Quality

Filter lineage

All assets

Up and Downstream

Last 3 months

See lineage graph

Name	Direction	Type	Last activity
angajati_it utm-master-an2-sd&ia-dl.mironela	↓ Downstream	Table	5 minutes ago
Laborator 1 Big Data	↓ Downstream	Notebook	5 minutes ago
Laborator 1 Big Data	↑ Upstream	Notebook	21 minutes ago

< Previous

Next >

Catalog Explorer > utm-master-an2-sd&ia-dl > mironela >

angajati_it

<

Lineage-ului pentru tabelul angajati_it- descrie **relațiile de dependență** dintre acest tabel, sursele sale de date și procesele care au contribuit la crearea lui.

Se observă că tabelul **angajati_it** are **două elemente upstream**, adică două surse din care provin datele sau logica de creare.

Prima sursă upstream este **tabelul angajati**, ceea ce indică faptul că **angajati_it** a fost creat printr-o **transformare a datelor existente** în tabelul inițial. Această relație confirmă că datele din **angajati_it** nu sunt introduse direct, ci sunt rezultatul unui proces de filtrare, în care au fost selectați doar angajații din departamentul IT. Astfel, angajati reprezintă **sursa principală de date** în pipeline-ul Big Data.

A doua sursă upstream este **notebook-ul „Laborator 1 Big Data”**. Acest lucru arată că procesul de creare a tabelului **angajati_it** a fost declanșat și controlat dintr-un notebook Databricks. Notebook-ul conține comenzile SQL care definesc transformarea datelor și joacă rolul de **motor al procesării batch**.

Lineage-ul evidențiază un **pipeline de date de tip batch**, în care:

- datele sunt preluate dintr-un tabel sursă (angajati);
- sunt procesate printr-o transformare logică (filtrare);
- rezultatul este stocat într-un nou tabel (angajati_it);
- întregul proces este orchestrat dintr-un notebook Databricks.

Această reprezentare vizuală demonstrează modul în care Big Data permite **trasabilitatea completă a datelor**, de la sursă până la rezultat final. Lineage-ul este esențial pentru înțelegerea fluxului de date, pentru audit, depanare și analiză de impact, deoarece permite identificarea rapidă a sursei datelor și a proceselor care le-au generat.

În Databricks: nu există rânduri stocate într-o bază clasică, nu există tabele fizice ca în Oracle/MySQL, există doar fișiere în Data Lake.

CREATE TABLE studenti_sql (...) USING DELTA;
creează structura, creează metadata, nu scrie date până la INSERT
După INSERT, datele sunt: fișiere Parquet în Data Lake

Comenzi pentru navigarea și explorarea datelor în Databricks (Unity Catalog)

Afișarea cataloagelor

SHOW CATALOGS;

Afișează toate cataloagele disponibile în Unity Catalog.

Selectarea unui catalog

USE CATALOG `utm-master-an2-sd&ia-dl`;

Setează catalogul curent pentru comenzile următoare.

Afișarea schemelor

SHOW SCHEMAS;

Afișează toate schemele din catalogul curent.

Selectarea unei scheme

USE SCHEMA mironela;

Setează schema curentă pentru lucrul cu tabele.

Afișarea tabelelor

SHOW TABLES;

Afișează toate tabelele din schema curentă.

Structura unui tabel

DESCRIBE TABLE angajati;

Afișează coloanele și tipurile de date ale tabelului.

Conținutul unui tabel

SELECT * FROM angajati LIMIT 10;

Afișează primele rânduri din tabel.

Număr de rânduri

SELECT COUNT(*) FROM angajati;

Returnează numărul total de înregistrări.

Istoric modificări (Delta)

DESCRIBE HISTORY angajati;

Afișează istoricul modificărilor tabelului.

Lineage din UI

Data → Catalog → Schema → Table → Lineage

Permite vizualizarea relațiilor upstream și downstream.

Afisare permisiuni

SHOW GRANTS ON CATALOG `utm-master-an2-sd&ia-dl`;

SHOW GRANTS ON SCHEMA `utm-master-an2-sd&ia-dl`.mironela;

SHOW GRANTS ON TABLE `utm-master-an2-sd&ia-dl`.mironela.angajati;

USE CATALOG `utm-master-an2-sd&ia-dl`;

USE SCHEMA samples;